

Исследование динамики вероятностей слов, эффективного контекстного окна и доменной адаптации через n -граммную перплексию

Фундаментальная разработка архитектуры собственной большой языковой модели (LLM) требует глубокого переосмысления механизмов, которые лежат в основе генерации текста, оценки внутренней уверенности нейронной сети и управления оперативной памятью модели. В условиях детерминированного вывода, когда вероятностный семплер полностью исключается из архитектуры для обеспечения строгой воспроизводимости и стабильности, на первый план выходят математические проблемы преобразования вероятностей субсловных токенов в вероятности полноценных слов. Дополнительную сложность вносит эффект деградации внимания на больших объемах данных, известный как проблема эффективного контекстного окна, а также необходимость динамической адаптации модели к новым узкоспециализированным доменам. Данное исследование представляет собой исчерпывающий анализ метрик вероятностей, методов локализации точки перегиба (локтя) n -граммной перплексии, а также механизмов автономной эволюции кода и непрерывного обучения в контексте, что в совокупности формирует строгий теоретический фундамент для реализации детерминированной LLM.

Декомпозиция вероятностных распределений: От токенов к словам

При анализе уверенности языковой модели критически важно различать вероятностные распределения на уровне токенов и на уровне семантически осмысленных слов. Современные архитектуры трансформеров оперируют субсловными единицами, сформированными с помощью алгоритмов токенизации, таких как Byte Pair Encoding (BPE) или WordPiece. Данные алгоритмы оптимизируют вычислительную эффективность и размер словаря, однако они создают фундаментальный разрыв между лингвистической структурой языка и математической формой выходных логитов модели. Когда модель генерирует текст, она оценивает условную вероятность каждого последующего токена на основе предшествующего контекста. Однако прямое перемножение вероятностей субсловных токенов для получения итоговой вероятности слова приводит к систематическим искажениям, которые делают невозможным точное построение доверительных интервалов.

Математическая коррекция вероятностей слов

Проблема усугубляется в зависимости от типа используемого токенизатора. Модели,

использующие токенизаторы с маркировкой начала слова (beginning-of-word, BoW), к которым относится все семейство архитектур GPT, подвержены так называемой «ошибке маргинализации». В стандартной парадигме вероятность слова вычисляется как произведение вероятностей его составных частей. Однако исследования доказывают, что для BoW-токенизаторов такой подход математически некорректен, так как он не учитывает альтернативные пути формирования того же слова через другие префиксы.¹

Для получения истинной контекстной вероятности слова $p(w|w_{<t})$, которая необходима для построения стабильного доверительного интервала, требуется применять корректирующий коэффициент. Истинная вероятность вычисляется по следующей формуле:

$$p(w|w_{<t}) = p(sw|sw_{<t}) \frac{\sum_{s \in S_{bow}} p(s|sw_{<t} \circ sw)}{\sum_{s \in S_{bow}} p(s|sw_{<t})}$$

В данном уравнении sw представляет собой последовательность субсловных токенов, а S_{bow} обозначает подмножество словаря токенизатора, содержащее маркеры начала новых слов (например, токены, начинающиеся с пробела или специального символа 'Ġ').² Данная формула устраняет смещение, возникающее из-за того, что модель резервирует часть вероятностной массы на продолжение текущего слова вместо начала нового. Вычисление этого корректирующего коэффициента может быть выполнено в рамках одного прямого прохода модели (forward pass), что делает его вычислительно эффективным для интеграции в разрабатываемую архитектуру. Эмпирические результаты показывают, что применение данной формулы кардинально меняет показатели предсказуемости слов в задачах оценки понимания предложений и лексической оптимизации, предоставляя разработчикам истинные значения сюрпризала (surprisal).⁴

Эмпирическая энтропия и стабильность распределений

Для понимания того, как вероятности слов ведут себя на различных масштабах данных, необходимо рассмотреть концепцию эмпирической энтропии. Исторические оценки энтропии английского языка, проведенные Клодом Шенноном, удивительно точно совпадают с современными эмпирическими данными, извлеченными из гигантских корпусов, таких как WikiText (103 миллиона токенов на уровне слов) и Google Books (анализ от 1-грамм до 9-грамм).⁶ Исключением является лишь оценка Шеннона для 7-граммной символьной энтропии, которая оказалась аномально выше, чем для 6-граммной. В контексте разработки детерминированной LLM, анализ эмпирической энтропии показывает, почему модели склонны к переобучению на определенных наборах данных: например, значения энтропии как на уровне символов, так и на уровне слов для датасета WikiText-2 стремительно убывают, что указывает на высокую предсказуемость лексики.⁶ Понимание этой базовой энтропии критически важно, поскольку оно формирует математический пол (нижнюю границу) для ширины доверительного

интервала: если базовая энтропия домена высока, доверительный интервал вероятности слова никогда не сожмется до нуля, даже при идеальной архитектуре модели.

Построение доверительных интервалов в условиях детерминированного вывода

Отказ от использования стохастических семплеров (таких как температурное масштабирование, top-k или top-p фильтрация) является необходимым шагом для достижения стабильности доверительных интервалов. При использовании семплера генеративный процесс превращается в авторегрессионный стохастический процесс, где случайность накапливается: случайный выбор первого токена меняет весь последующий контекст, что приводит к экспоненциальному расхождению вероятностных распределений для последующих слов.⁷ В условиях жестко детерминированного вывода (жадный поиск или лучевой поиск) модель всегда выбирает путь с максимальной вероятностью, что позволяет напрямую анализировать стабильность логитов.

Теория «Туннеля восприятия» и проблема излишней уверенности

Однако извлечение доверительных интервалов напрямую из сырых логитов сопряжено с серьезными концептуальными трудностями. Исследования показывают, что языковые модели систематически страдают от излишней уверенности (overconfidence) в своих предсказаниях.⁸ Набор данных FermiEval, предназначенный для оценки калибровки доверительных интервалов в задачах оценки порядка величин (Fermi-style estimation), демонстрирует, что номинальный 99-процентный доверительный интервал, сгенерированный моделью, фактически покрывает истинное значение лишь в 65 процентах случаев.⁹

Этот феномен объясняется теорией «Туннеля восприятия» (LLM Perception Tunnel). Согласно этой теории, когда языковая модель осуществляет вывод в условиях высокой неопределенности, она математически ведет себя так, словно производит выборку из усеченного (truncated) региона выведенного распределения, полностью игнорируя хвосты распределения.⁹ Следовательно, сырые логиты токенов отражают скорее вероятность появления текста в обучающей выборке, нежели истинную семантическую уверенность модели в правильности ответа.¹² Высокая вероятность логита может быть следствием синтаксической предсказуемости (например, грамматического принуждения к использованию определенного предлога), а не фактической уверенности в факте.

Методы калибровки и структурная уверенность

Для решения проблемы излишней уверенности и стабилизации доверительных интервалов применяются несколько продвинутых математических подходов:

Подход к оценке уверенности	Механизм действия	Преимущества	Ограничения
Ожидаемая ошибка калибровки (ECE)	Группировка доверительных интервалов в фиксированные бакеты и сравнение средней уверенности со средней ошибкой внутри бакета. ⁸	Позволяет математически выровнять распределение логитов с реальной вероятностью успеха.	Требует наличия размеченного валидационного датасета для настройки калибровочной кривой.
Квантильная регрессия	Прямая оценка формы распределения без строгих параметрических допущений с использованием функции потерь Пинбола для извлечения межквартильного размаха (IQR). ¹⁴	Модель может предсказывать дисперсию и ширину доверительного интервала напрямую из внутренних активаций.	Требует дополнительного обучающего прохода для настройки зондов (probes) поверх слоев модели.
Структурная уверенность (Structural Confidence)	Анализ траектории скрытых состояний (hidden-state trajectory) на финальных слоях с использованием спектральных дескрипторов и метрик локальной вариации. ¹⁵	Работает за один детерминированный проход. Обладает высокой устойчивостью к доменным сдвигам.	Вычислительно затратно для извлечения градиентов формы многомерных тензоров на каждом шаге.

Метод структурной уверенности представляет наибольший интерес для разработки детерминированной LLM. Вместо того чтобы полагаться на поверхностные логиты токенов, этот метод отслеживает внутреннюю динамику вычислений. Если модель уверена в генерируемом слове, траектория ее скрытых состояний эволюционирует

плавно и однонаправленно. Если же модель сталкивается с информационной неопределенностью (даже если финальный логит случайно оказался высоким), траектория начинает демонстрировать высокочастотные осцилляции и глобальную структурную несогласованность.¹⁵ Применение структурной уверенности на кросс-доменных бенчмарках, таких как FEVER (проверка фактов), SciFact (научные утверждения) и TruthfulQA, показало, что этот метод значительно превосходит традиционные подходы на базе вероятностей по метрикам AUROC и AUPR, при этом снижая вычислительные затраты в 4–5 раз по сравнению с методами консистентности семплирования (SelfCheckGPT).¹⁵

В контексте поставленной задачи, вероятность слов становится стабильной по доверительному интервалу тогда, когда структурная дисперсия скрытых состояний падает ниже эмпирически установленного порога, а откорректированные по методу Pimentel & Meister вероятности слов формируют интервал (вычисленный через квантильную регрессию), ширина которого перестает экспоненциально флуктуировать при добавлении новых токенов.

Максимальное эффективное контекстное окно (MECW) и проблема контекстной гнили

Определение того, после какого объема контекста доверительные интервалы слов теряют стабильность, требует строгого разделения архитектурных заявлений и эмпирической реальности. Современные провайдеры языковых моделей декларируют гигантские размеры максимального контекстного окна (Maximum Context Window, MCW) — от 128 тысяч до нескольких миллионов токенов.¹⁷ Однако архитектурная способность модели принять миллион токенов не означает ее когнитивной способности использовать эту информацию. В связи с этим вводится концепция максимального эффективного контекстного окна (Maximum Effective Context Window, MECW).

Феноменология деградации контекста

MECW определяется как самая длинная последовательность входных токенов для конкретного типа задачи, при которой добавление новых токенов вызывает измеримую деградацию качества вывода модели (снижение точности или резкое расширение доверительного интервала).¹⁸ В масштабном исследовании, охватившем сотни тысяч точек данных на моделях уровня GPT-5, LLaMA 4, Claude 3 и Gemini 2.0, было выявлено, что абсолютно все протестированные модели не достигают своего заявленного MCW, причем разрыв может составлять более 99 процентов.¹⁸

Деградация не является линейной; она проявляется через феномен «контекстной гнили» (Context Rot). Некоторые передовые модели демонстрируют фатальные сбои при подаче всего 100 токенов, а большинство испытывает критическое падение точности к отметке в 1000 токенов.¹⁸ Уровень галлюцинаций напрямую коррелирует с длиной контекста: если при объеме до 500 токенов модель может демонстрировать нулевой уровень

галлюцинаций, то при достижении 2000 токенов уровень ошибок может возрастать до 99 процентов.¹⁸

Важнейшим открытием является то, что размер MECW не является статической величиной для конкретной архитектуры; он динамически сдвигается в зависимости от типа решаемой задачи. Это можно проиллюстрировать на примере тестирования модели Granite 3.1 8B с заявленным окном в 128 тысяч токенов ¹⁷:

Тип задачи (Granite 3.1 8B)	Эффективност ь при 32K токенов	Эффективност ь при 64K токенов	Эффективност ь при 128K токенов	Характер деградации
Извлечение общих слов (CWE)	Высокая	Резкое падение	0.8%	Катастрофический отказ памяти из-за перенасыщения лексическими паттернами
Многоключевой поиск (niah_multikey_3)	Высокая	Умеренное падение	20.0%	Проблема позиционного смещения и интерференции ключей
Ответы на вопросы (QA_2)	Высокая	Умеренное падение	48.0%	Потеря логических связей в середине длинного контекста
Отслеживание переменных (vt)	>90%	>90%	Снижение	Высокая устойчивость к длине благодаря узкому фокусу

				внимания
--	--	--	--	----------

Позиционное смещение и фундаментальные пределы

Традиционно деградацию в средних позициях контекста объясняли эффектом «Lost in the Middle» (позиционное смещение), предполагая, что модели обращают внимание только на начало и конец документа.²⁰ Однако более глубокий анализ с использованием методов семантического выравнивания на базе кросс-энкодеров (cross-encoders), которые оценивают не поверхностное совпадение n-грамм, а глубокие смысловые связи, показывает иную картину. Языковые модели способны извлекать информацию из средних позиций эффективнее, чем предполагали старые метрики.²¹ Истинная причина деградации заключается не в слепоте к середине документа, а в разрушении вероятностных доверительных интервалов из-за накопления информационного шума.

Каждая архитектура имеет свой предел, продиктованный уровнем шума в обучающих данных (label noise). В соответствии с теорией масштабирования, даже при бесконечном объеме обучающих данных ненулевой уровень шума устанавливает жесткий математический пол для средней ошибки.²² Никакие инженерные инновации — будь то улучшенные механизмы роутинга, векторный поиск (RAG) или модификации позиционного кодирования (RoPE) — не могут преодолеть этот потолок. Более того, принудительная подача избыточного контекста в системы RAG может привести к тому, что эффективность модели упадет ниже базового уровня.¹⁸ Таким образом, размер эффективного окна определяется точкой, в которой кумулятивная энтропия контекста начинает превышать способность механизма внимания (attention mechanism) отфильтровывать шумовые логи́ты от семантически значимых сигналов.

Локализация точки насыщения домена: Метод локтя для n-граммной перплексии

Понимание того, как модель адаптируется к различным тематическим доменам (например, юридическим текстам, медицинским статьям или исходному коду), требует создания метрики, которая объективно укажет, когда модель «усвоила» структуру домена и перестала извлекать пользу из дополнительного контекста. Предложенный подход с использованием разбиения на n-граммы и построения графика средней перплексии, с последующим поиском точки остановки сильного убывания (аналог метода локтя в алгоритме K-means), является математически строгим и обоснованным решением.²³

Обоснование выбора n-граммной архитектуры

Использование n-грамм вместо одиночных слов (униграмм) или полных предложений базируется на природе лингвистической избыточности и частотного распределения.

Исследования показывают, что до 98 процентов дисперсии в поведении языковой модели на уровне слов можно объяснить тремя эвристиками: вероятностью униграммы (базовой частотностью), вероятностью n-граммы и семантическим сходством между словом и контекстом.²⁵ Применение униграмм неэффективно, так как они в основном представляют функциональные слова (предлоги, союзы), которые не несут доменной специфики. Напротив, n-граммы захватывают контекстуальные нюансы (например, позволяя отличить финансовый термин "money bank" от географического "river bank"), что делает их идеальными маркерами для оценки усвоения предметной области.²³ Кроме того, методы фильтрации и анализа на основе n-граммной перплексии стабильно превосходят классификационные подходы (такие как AskLLM или FastText) при идентификации релевантных доменных структур.²⁷

Алгоритм реализации метода локтя через перплексию

Процесс локализации точки насыщения домена должен выполняться независимо для каждой предметной области ввиду различий в их лексической энтропии. Алгоритм реализуется через следующую последовательность шагов:

1. **Токенизация и морфологический анализ:** Корпус текстов специфического домена разбивается на морфемы. Производится фильтрация стоп-слов с использованием тегов частей речи (POS-тегов), после чего генерируются уникальные n-граммы, как

правило, в диапазоне $1 \leq n \leq 5$.

2. **Вычисление кросс-энтропии (перплексии):** Для каждого увеличивающегося подмножества контекста (или для каждого нового кластера тематических данных) вычисляется средняя перплексия логитов модели. Перплексия представляет собой экспоненту от негативного логарифмического правдоподобия:

$Perplexity(y) = \exp(-\frac{1}{M} \sum_{t=1}^M \log p(y_t | y_{<t}))$. Чем ниже перплексия, тем меньше модель «удивлена» представленным n-граммам.²⁸ Важно отметить, что при

вычислении вероятностей $p(y_t)$ должна применяться корректирующая формула Pimentel & Meister для устранения искажений субсловной токенизации.

3. **Построение функции убывания:** Формируется график зависимости средней перплексии от объема поданного доменного контекста. По мере того как модель распознает статистические паттерны домена, кривая перплексии демонстрирует крутое экспоненциальное падение. Однако, когда базовые лексические паттерны исчерпаны, кривая переходит в асимптотическое плато, отражая неотъемлемый структурный шум языка.
4. **Локализация точки локтя:** Точка, в которой перплексия перестает сильно убывать, определяется математически. Это достигается путем вычисления второй производной функции потерь (или кривой перплексии). Координата, в которой вторая производная максимизируется (точка наибольшего изменения кривизны), и есть искомый «локоть».²⁹ Дополнительно для верификации могут применяться

методы силуэтного анализа (Silhouette Analysis) или индекс Калински-Харабаша, которые традиционно используются в кластеризации для оценки компактности данных.³⁰

Эта точка локтя указывает на оптимальный размер кластера или максимальный полезный объем контекста для данного домена. За пределами этой точки подача дополнительной информации не снижает неопределенность модели (доверительные интервалы перестают сужаться), а лишь необоснованно поглощает вычислительные ресурсы и увеличивает риск выхода за пределы MECW. Этот контекстно-агностический подход (context-agnostic property) позволяет модели эффективно абстрагироваться от частностей и захватывать чистую грамматическую и семантическую структуру домена.²³

Непрерывное обучение в контексте и когнитивные задачи (meet_03_05.MD)

Исследование механизмов удержания памяти и выполнения сложных задач, описанных в артефактах типа meet_03_05.MD, напрямую пересекается с выявленными границами MECW и логикой n-граммной перплексии. Основным механизмом, обеспечивающим выполнение долгосрочных когнитивных задач в рамках одного контекстного окна, является концепция непрерывного обучения в контексте (In-Context Continual Learning, ICCL).³²

Динамика удержания и интерференция задач

ICCL не подразумевает изменения внутренних весов модели (параметрического обучения). Вместо этого оно опирается на инференс-динамику удержания, которая демонстрирует структурированные паттерны, поразительно схожие с когнитивными процессами человека, такими как эффект распределенного повторения (spacing effects) и усиление через извлечение (retrieval-based strengthening).³² При выполнении многоэтапных задач из meet_03_05.MD, если релевантные n-граммы распределены по контексту с определенными интервалами, модель способна поддерживать стабильные вероятности слов на протяжении более длительного времени.

Однако эта способность жестко ограничена феноменом перекрестной интерференции задач (cross-task interference) и архитектурными лимитами токенов. Например, в экспериментах с ICCL параметры подбираются строго в пределах функциональных ограничений моделей: для DeepSeek-R1 эффективный лимит часто устанавливается в районе 4096 токенов, а для LLaMA3-8B — около 8192 токенов.³² При превышении этих порогов интерференция между различными когнитивными задачами начинает разрушать структуру внимания. Оценка задач в мультязычных средах (например, в рамках бенчмарка MLRBench) показывает, что хотя модели успешно справляются с поверхностным извлечением фактов (Retrieval), их точность катастрофически падает при необходимости агрегации (Aggregation) и многошагового вывода (Multi-hop Inference).³³

Задачи, связанные с неопределенностью (Uncertainty), демонстрируют наихудшие результаты: модель начинает отвечать с необоснованно высокой уверенностью (высокими логитами), не выражая необходимой двусмысленности, что вновь отправляет нас к проблеме туннеля восприятия. Таким образом, применение метода локтя перплексии позволяет динамически определить момент, когда эффект интерференции начинает подавлять эффект распределенного повторения, сигнализируя о том, что когнитивный ресурс контекстного окна исчерпан.

Автономная эволюция на уровне репозитория (hypothesis.md)

Наиболее совершенной практической реализацией концепций MECW, оценки уверенности и управления контекстом являются системы автономной генерации и эволюции программного кода, исследование которых представлено в документах hypothesis.md. Революционным прорывом в этой области является фреймворк SATLUTION, разработанный исследователями из NVIDIA, который расширяет парадигму агентов LLM от оптимизации мелких алгоритмических ядер до автономной эволюции целых репозиторий (десятки файлов, десятки тысяч строк C/C++ кода) для решения NP-полных задач, таких как Boolean Satisfiability (SAT).³⁴

Архитектура SATLUTION и управление памятью агентов

Сложность работы с проектами масштаба репозитория заключается в том, что весь исходный код физически не может быть помещен в эффективное контекстное окно модели (MECW) без вызова контекстной гнили. Если подать агенту весь репозиторий, вероятностные распределения логитов дестабилизируются, что приведет к ошибкам работы с памятью (segmentation faults), генерации некорректных синтаксических конструкций и провалам в валидации.³⁶

Для обхода этого ограничения SATLUTION и аналогичные фреймворки (например, архитектура Kairos) используют многоуровневую систему управления памятью и жесткую изоляцию агентов:

1. **Разделение памяти на слои (L0, L1, L2):** В архитектуре Kairos память модели сегрегируется. Слой L0 содержит неизменяемые правила управления и мета-навыки. Слой L1 хранит проектно-специфичные знания (например, стандарты кодирования coding_rules). Слой L2 выполняет функцию временного контекста сессии, где создается файл HYPOTHESIS.md.³⁷ Этот файл служит внешним когнитивным буфером: в нем фиксируются рабочие гипотезы, результаты проб и ошибок, а также направления эволюции. Вместо того чтобы перегружать контекст модели всем исходным кодом, агент обращается к сжатому смысловому вектору из HYPOTHESIS.md, размер которого всегда находится в зоне оптимальной n-граммной перплексии (до точки локтя).
2. **Оркестрация агентов (Planning and Coding):** Процесс разделяется между

Агентом-Планировщиком и Агентом-Кодировщиком. Планировщик читает HYPOTHESIS.md, анализирует результаты предыдущих тестов и генерирует краткие, строго локализованные инструкции. Кодировщик, обладая абсолютно чистым контекстным окном, реализует только эту конкретную функцию.³⁴

3. **Цикл Generate-Compile-Test-Analyze-Evolve:** Эволюция кода происходит через жесткий, не опирающийся на субъективную уверенность LLM цикл обратной связи. Сгенерированный код проходит двухэтапный конвейер верификации. Сначала выполняется дымовое тестирование (smoke test) и проверка компиляции. В случае успеха код развертывается на распределенных CPU-кластерах для масштабного тестирования производительности (вычисление PAR-2 score на бенчмарках соревнований SAT Competition).³⁴
4. **Динамическая база правил:** Если генерация приводит к фатальным сбоям (например, к небезопасным статическим состояниям или нестандартным функциям памяти, выявляемым через pre-commit хуки), система не пытается просто «попросить модель исправить ошибку» в том же окне. Вместо этого ошибка анализируется, и система автоматически генерирует патч правил, который добавляется в динамическую базу.³⁶ В будущем эти правила принудительно внедряются в системный промпт, что предотвращает регрессию кодовой базы и блокирует галлюцинации до того, как они начнут искажать логику.

Этот многоступенчатый механизм демонстрирует, что успешная реализация сложных систем на базе LLM строится не на безграничном расширении контекстного окна, а на его радикальном ограничении рамками MECW, где вероятности слов остаются математически стабильными, а долгосрочная память переносится на внешние структурированные носители.

Заключение: Архитектурный синтез для детерминированной LLM

Синтезируя проанализированные математические модели, эмпирические наблюдения и инженерные практики, можно сформировать концептуальный пайплайн для реализации собственной языковой модели, свободной от стохастического шума семплеров:

- **Фундамент вероятностей:** Архитектура должна вычислять вероятности на уровне полных слов, применяя корректирующий коэффициент Pimentel & Meister для обработки префиксов BoW-токенов, обеспечивая тем самым истинные значения сюрприза и кросс-энтропии.
- **Оценка уверенности:** Система должна отказаться от сырых логов как меры истины из-за эффекта «туннеля восприятия». Вместо этого калибровка доверительных интервалов должна осуществляться через анализ межквартильного размаха активаций (квантильная регрессия) или, что более предпочтительно, через оценку структурной уверенности на основе спектральной динамики траекторий скрытых состояний.

- **Управление контекстным окном:** Система должна внедрить непрерывный мониторинг MECW. Как только ширина доверительного интервала начинает неконтролируемо расширяться, система фиксирует предел оперативной памяти для текущей задачи.
- **Адаптация к домену:** Для каждого нового домена должен запускаться предварительный анализ: разбиение корпуса на n-граммы, вычисление средней перплексии логитов и локализация точки перегиба (локтя) через вторую производную. Эта координата установит жесткий лимит длины контекста для работы в данном домене.
- **Автономная оркестрация:** При достижении лимитов MECW модель должна вызывать внешние скрипты для сжатия информации в артефакты типа hypothesis.md, сбрасывать контекст и инициировать новых агентов с чистой памятью по паттерну фреймворка SATLUTION.

Этот подход трансформирует разработку языковой модели из процесса вероятностного угадывания в строго детерминированный, математически обоснованный инженерный конвейер.

Works cited

1. How to Compute the Probability of a Word - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2406.14561v2>
2. How to Compute the Probability of a Word - ACL Anthology, accessed May 13, 2026, <https://aclanthology.org/2024.emnlp-main.1020.pdf>
3. How to Compute the Probability of a Word - ETH Zurich Research Collection, accessed May 13, 2026, <https://www.research-collection.ethz.ch/server/api/core/bitstreams/79a45914-f668-4b1e-affe-e62a75d38849/content>
4. How to Compute the Probability of a Word - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2406.14561v1>
5. On the Proper Treatment of Units in Surprisal Theory - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2604.28147v1>
6. Evaluation Metrics for Language Modeling - The Gradient, accessed May 13, 2026, <https://thegradient.pub/understanding-evaluation-metrics-for-language-models/>
7. Demystifying Randomness in AI - Graphite.io, accessed May 13, 2026, <https://graphite.io/five-percent/demystifying-randomness-in-ai>
8. Cycles of Thought: Measuring LLM Confidence through Stable Explanations - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2406.03441v1>
9. (PDF) LLMs are Overconfident: Evaluating Confidence Interval Calibration with FermiEval, accessed May 13, 2026, https://www.researchgate.net/publication/397188375_LLMs_are_Overconfident_Evaluating_Confidence_Interval_Calibration_with_FermiEval
10. LLMs are Overconfident: Evaluating Confidence Interval Calibration with FermiEval - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2510.26995v1>

11. Eliciting Numerical Predictive Distributions of LLMs Without Autoregression - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2603.02913v1>
12. On Verbalized Confidence Scores for LLMs - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2412.14737v2>
13. Graph-based Confidence Calibration for Large Language Models - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2411.02454v2>
14. Eliciting Numerical Predictive Distributions of LLMs Without Auto-Regression - OpenReview, accessed May 13, 2026, <https://openreview.net/pdf?id=jwzClhPT0j>
15. Trust in One Round: Confidence Estimation for Large Language Models via Structural Signals - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2602.00977v1>
16. Trust in One Round: Confidence Estimation for Large Language Models via Structural Signals - ResearchGate, accessed May 13, 2026, https://www.researchgate.net/publication/400369925_Trust_in_One_Round_Confidence_Estimation_for_Large_Language_Models_via_Structural_Signals
17. Unlocking the Effective Context Length: Benchmarking the Granite-3.1-8b Model - Red Hat, accessed May 13, 2026, <https://www.redhat.com/en/blog/unlocking-effective-context-length-benchmarking-granite-31-8b-model>
18. [2509.21361] Context Is What You Need: The Maximum Effective Context Window for Real World Limits of LLMs - arXiv, accessed May 13, 2026, <https://arxiv.org/abs/2509.21361>
19. The Maximum Effective Context Window for Real World Limits of LLMs - Advances in Artificial Intelligence and Machine Learning, accessed May 13, 2026, <https://www.oajaiml.com/uploads/archivepdf/643561268.pdf>
20. Self-Consistency Falls Short! The Adverse Effects of Positional Bias on Long-Context Problems | Transactions of the Association for Computational Linguistics - MIT Press Direct, accessed May 13, 2026, <https://direct.mit.edu/tac/article/doi/10.1162/TACL.a.625/136156/Self-Consistency-Falls-Short-The-Adverse-Effects>
21. Not Lost After All: How Cross-Encoder Attribution Challenges Position Bias Assumptions in LLM Summarization - ACL Anthology, accessed May 13, 2026, <https://aclanthology.org/2025.findings-emnlp.846.pdf>
22. On the Fundamental Limits of LLMs at Scale - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2511.12869v1>
23. Prior-based Noisy Text Data Filtering: Fast and Strong Alternative For Perplexity, accessed May 13, 2026, <https://openreview.net/forum?id=VDjbFzbD2f>
24. BloomIntent: Automating Search Evaluation with LLM-Generated Fine-Grained User Intents, accessed May 13, 2026, <https://arxiv.org/html/2509.18641v1>
25. Language Model Behavioral Phases are Consistent Across Architecture, Training Data, and Scale - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2510.24963v1>
26. NeurIPS Poster Language Model Behavioral Phases are Consistent Across Architecture, Training Data, and Scale, accessed May 13, 2026, <https://neurips.cc/virtual/2025/poster/118883>

27. Prior-based Noisy Text Data Filtering: Fast and Strong Alternative For Perplexity - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2509.18577v4>
28. Root Cause Prediction from Log Data using Large Language Models - Diva-Portal.org, accessed May 13, 2026, <https://www.diva-portal.org/smash/get/diva2:1875371/FULLTEXT01.pdf>
29. Polysemanticity in human hippocampal neurons - bioRxiv, accessed May 13, 2026, <https://www.biorxiv.org/content/10.64898/2026.05.02.722435v1.full.pdf>
30. Human vs. LLM Creativity: A Comparative Analysis of Task-Dependent Asymmetry and Linguistic Mechanisms - MDPI, accessed May 13, 2026, <https://www.mdpi.com/2079-3200/14/2/27>
31. Evaluating LLM-Based Mobile App Recommendations: An Empirical Study - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2510.18364v1>
32. In-Context Learning can Perform Continual Learning Like Humans - OpenReview, accessed May 13, 2026, <https://openreview.net/forum?id=I4OTaUTTVR>
33. Can LLMs reason over extended multilingual contexts? Towards long-context evaluation beyond retrieval from haystacks - ACL Anthology, accessed May 13, 2026, <https://aclanthology.org/2026.eacl-long.290.pdf>
34. SATLUTION: Autonomous Evolution of SAT Solvers - Emergent Mind, accessed May 13, 2026, <https://www.emergentmind.com/topics/satlution-framework>
35. [Literature Review] Autonomous Code Evolution Meets NP-Completeness, accessed May 13, 2026, <https://www.themoonlight.io/en/review/autonomous-code-evolution-meets-np-completeness>
36. Autonomous Code Evolution Meets NP-Completeness - arXiv, accessed May 13, 2026, <https://arxiv.org/html/2509.07367v1>
37. masaomi/KairosChain_2026 - GitHub, accessed May 13, 2026, https://github.com/masaomi/kairoschain_2026