

Отчет о текущем состоянии проекта Qwen

Дата среза: 13.05.2026 **Репозиторий:** D:\HANDMADE_LLM\REPO\qwen **Цель отчета:** зафиксировать фактически выполненные исследования, notebook-прогоны, полученные метрики, артефакты и ограничения проекта.

Оглавление

1. Краткий вывод 2. Фактически выполнено 3. Итоги встреч: требования и гипотезы 4. Датасеты и выбранная смесь 5. Data filtering и токенизация 6. Исследования распределений Qwen 7. MECW и контекстное окно 8. Large-corpus n-gram sweep 9. Метрики оценки pretrain 10. Что пока не сделано 11. Практический статус проекта

Краткий вывод

Репозиторий сейчас является исследовательским черновиком по подготовке pretrain/continued-pretrain пайплайна на базе Qwen/Qwen3. Это не завершенная training-инфраструктура и не репозиторий с обученной собственной моделью. Фактически подтверждены следующие направления:

- проведен ресерч датасетов и собрана рабочая гипотеза смеси английского корпуса: **FineWeb 30% / FineWeb-Edu 50% / FineMath 20%**;
- собрана пробная смесь корпуса на **100,048 токенов** из FineWeb, FineWeb-Edu и FineMath;
- tokenizer/bin-конвертер прогнал **98,582 токена**, vocab size **248,077**, dtype `uint32` ;
- выполнен Qwen3-4B next-token/next-word distribution experiment на `ag_news` , **32 примера**, CPU;
- выполнен MECW demo-прогон на `gpt2` , CPU, без ошибок, с **5 PNG-графиками**;
- локально выполнен large-corpus n-gram sweep на `fineweb-edu sample-10BT` : **1,627 документов**, **8,001,974 bytes**, `Qwen/Qwen2.5-0.5B` , CPU;
- полноценный pretrain/continued-pretrain запуск модели в репозитории **не зафиксирован**.

Главный фактический прогресс проекта: команда перешла от общих планов к измеримым диагностическим прототипам для данных, токенизации, распределений следующего токена/слова, оценки effective context window и выбора размера n-грамм.

Фактически выполнено

Блок	Артефакт	Фактический результат	Ограничение
Dataset research	<code>datasets/english-datasets.MD</code> , <code>datasets/datasets_yaroslav.md</code> , <code>datasets/daniil.md</code>	Составлены списки русских, английских, SFT и preference датасетов; предложена смесь FineWeb/FineWeb-Edu/FineMath	Нет финальной спецификации 50-70B token mix

Блок	Артефакт	Фактический результат	Ограничение
Data filtering sample	data-filtering/data-filtering.ipynb , data-filtering/corpus_sample.txt	Собрано 100,048 токенов : FineWeb ~30,101, FineWeb-Edu ~50,213, FineMath ~19,732	Это малый sample, не production corpus
Bin conversion	data-filtering/bin-converter.ipynb	Vocab size 248,077 , dtype uint32 , обработано 98,582 токена	Output path был <code>/content/drive/...</code> ; bin-файл не лежит в репозитории
Старые Qwen distribution notebooks	qwen-distributions_v1.ipynb , qwen-distributions-v2.ipynb	Построены top-token продолжения и графики распределений	<code>token_tree.json</code> заявлен в output, но tracked JSON отсутствует
Qwen3-4B next-token/word distribution	research/qwen_next_token_word_distribution_ru.ipynb , research/qwen_next_token_word_distribution_report.md	Qwen/Qwen3-4B-Base , ag_news test , 32 примера, 4 графика, entropy/JS/top-overlap метрики	Word-level слой является BoW-аппроксимацией, не полной маргинализацией
MECW/context-window notebook	research/llm_context_window_mecw_ru.ipynb , research/llm_context_window_results_ru.md	Полный прогон: 10 code cells, 0 ошибок, ~260 секунд, CPU, 5 PNG-графиков	Demo на <code>gpt2</code> ; MECW threshold намеренно чувствительный
L2 hypothesis buffer	research/hypothesis.md	Зафиксированы MECW flush entries с breach diagnostics и compressed state	Это demo паттерна, не production memory system
Large-corpus sweep	research/large_corpus_ngram_perplexity_entropy_report.md , research/large_corpus_ngram_perplexity_entropy_ru.ipynb , research/large_ngram_sweep_metrics.png	FineWeb-Edu sample-10BT, 1,627 docs, 8 MB, лучший score при <code>n=250</code>	Файлы внесены в research/.gitignore , то есть это локальные ignored artifacts

Итоги встреч: требования и гипотезы

Встреча 26.04

Источник: [results of the meetings/meet_26_04.MD](#)

На этой встрече был зафиксирован общий контур проекта:

- фокус только на **pretrain**, без ухода в post-training как основную задачу;
- рабочий язык на старте: **английский**, потому что доступнее качественные открытые корпуса;
- токенизатор: готовый tokenizer от Qwen;
- целевой порядок данных: **50-70B** токенов/параметров в постановке встречи;

- нужна категоризация датасетов, data loaders / data order;
- нужно изучить фильтрацию данных и реализовать фильтрационный pipeline;
- для обучения рассматривался ZeRO 0/1/2/3;
- отдельная задача: понять, какие данные сильнее всего влияют на изменения весов;
- метрики должны оценивать pretrain качество и близость поведения к Qwen.

Факт по текущему состоянию: требования заданы, но training pipeline и ZeRO-конфиги пока не реализованы как воспроизводимая инфраструктура в репозитории.

Встреча 03.05

Источник: [results of the meetings/meet_03_05.MD](#)

На этой встрече сформулирована исследовательская гипотеза: обучающие данные должны описываться моделью с похожей плотностью вероятности, что и эталонная выдача. Отсюда появились задачи:

- считать среднюю энтропию распределения следующего токена/слова для разных размеров n-грамм;
- найти точку стабилизации распределения при росте окна;
- сделать нарезку окон 3, 4, 5, 10, 25, 50, 100 токенов/слов;
- прогонять n-граммы через Qwen и собирать распределения следующего слова;
- найти способы визуализации распределений;
- исследовать TF-IDF/параметрическое описание текстов;
- написать метрику совпадения распределения датасета с Qwen;
- провести сквозной тест на разных корпусах.

Факт по текущему состоянию: часть задач выполнена в виде прототипов и прогонов: next-token distribution, word-level approximation, MECW, n-gram perplexity/elbow, large-corpus n sweep.

Встреча 11.05

Источник: [results of the meetings/meet_11_05.MD](#)

На этой встрече команда критически пересмотрела идею просто считать `mean(softmax)` по всем n-граммам:

- это дорого;
- плохо переносится с токенов на слова;
- плохо интерпретируется, потому что token-level вероятности не равны word-level вероятностям.

Были рассмотрены два пути:

1. Word-level/TF-IDF параметризация домена с последующим сравнением распределений. 2. Стандартный loss/perplexity подход: если модель дает низкий loss на корпусе, корпус близок ее обучающему распределению.

Факт по текущему состоянию: второй путь фактически стал сильнее подтвержден в notebook-прогонах через CE/PPL/n-gram sweep. Первый путь остался как гипотеза с признанными сомнениями по валидности TF-IDF постановки.

Датасеты и выбранная смесь

Русскоязычные кандидаты

Источник: [datasets/datasets.MD](#)

В репозитории зафиксированы следующие русскоязычные кандидаты:

Датасет	Назначение / комментарий
IlyaGusev/habr	302k статей Habr; полезен для технотекстов
danasone/oscar_ru	76 млн записей; новости/реклама/web
IlyaGusev/rulm	Малый подготовленный датасет, потенциально для токенизатора
IlyaGusev/gazeta	Новостная суммаризация
LDN00BW/List-of-Dirty-Naughty-Obscene-and-Otherwise-Bad-Words	Списки токсичной лексики, включая русский и транслит
c4	Common Crawl based corpus с языковыми разделами
IlyaGusev/librusec	Художественная литература
wikimedia/wikipedia	Wikipedia RU, очищенная от Markdown/ссылок

Также отмечены материалы по русской детоксификации и Vikhr как reference для русскоязычных моделей.

Англоязычные кандидаты

Источники: [datasets/english-datasets.MD](#) , [datasets/daniil.md](#) , [datasets/datasets_yaroslav.md](#)

В английском направлении собраны кандидаты для разных стадий:

Тип	Датасеты
Pretrain / continued pretrain	FineWeb, FineWeb-Edu, FineMath, OpenWebMath, SmolLM-Corpus, Cosmopedia, DCLM, Dolma, Stack-Edu, The Stack v2
SFT / instruct	SmolTalk, UltraChat 200k, Tulu-3 SFT mixture, OpenOrca
Preference / DPO / RL-like	UltraFeedback, HelpSteer2, Anthropic HH-RLHF, Tulu-3 datasets
Evaluation / Russian NLU	MERA, SAGE datasets

Рабочая смесь

В [datasets/english-datasets.MD](#) предложена смесь:

Источник	Доля	Роль
FineWeb	30%	Широкий web, общий словарь, разнообразие
FineWeb-Edu	50%	Качественный образовательный корпус, reasoning-friendly структура
FineMath	20%	Математика, логика, многошаговые рассуждения

Выбор сдвинут в сторону качества, образовательных текстов и математики, а не максимального объема грязного web. Это согласуется с заметками по [Textbooks Are All You Need](#) и small-model training intuition: при ограниченном бюджете полезнее повышать плотность обучающего сигнала, чем просто масштабировать шумный corpus.

Data filtering и токенизация

Пробный сбор корпуса

Источник: [data-filtering/data-filtering.ipynb](#)

Notebook output фиксирует:

- FastText-модель уже существует;
- FastText-модель загружена;
- цель: собрать **100,000** токенов;
- FineWeb: забрано примерно **30,101** токенов;
- FineWeb-Edu: забрано примерно **50,213** токенов;
- FineMath: забрано примерно **19,732** токенов;
- итог: **100,048** токенов.

Сохраненный sample: [data-filtering/corpus_sample.txt](#) , размер **459,389 байт**. Первые строки файла показывают англоязычный web/article текст, то есть sample действительно является текстовым корпусным фрагментом, а не пустым placeholder.

Bin converter

Источник: [data-filtering/bin-converter.ipynb](#)

Фактический output:

Параметр	Значение
Vocab size	248,077
dtype	<code>numpy.uint32</code>
Tokenized output	98,582 токена
Files	1
Output path в notebook	<code>/content/drive/MyDrive/data-filtering/bin</code>

Ограничение: бинарный файл не хранится в текущем tracked repo. Значит, notebook доказывает работоспособность конвертации на sample, но не оставляет в репозитории готовый `.bin` артефакт.

FastText/filtering research

Источник: [fasttext.md](#)

В `fasttext.md` разобрана математическая суть fastText как bag-of-n-grams + subword information + linear classifier, а не просто “векторизатора слов”. Важный практический вывод: fastText рассматривается как дешевый фильтр качества данных, который может заменить дорогой LLM-scoring при правильно подобранных seed examples и негативных сэмплах.

Факт реализации: в репозитории есть notebook-признаки загрузки FastText-модели, но production-grade iterative filtering pipeline в стиле Ultra-FineWeb пока не оформлен.

Исследования распределений Qwen

Root notebooks: v1/v2

Источники: `qwen-distributions_v1.ipynb` , `qwen-distributions-v2.ipynb`

`qwen-distributions_v1.ipynb` строил дерево top-token продолжений для prompt:

```
Искусственный интеллект меняет
```

В output notebook указано: `Дерево сохранено в token_tree.json` . В текущем tracked repo такого JSON-файла нет, поэтому этот результат надо считать notebook-output фактом, но не сохраненным репозиторным артефактом.

`qwen-distributions-v2.ipynb` расширил эксперимент и содержит 11 выполненных code cells, 25 outputs и 2 изображения. Это промежуточный шаг к более строгому отчету в папке `research` .

Qwen3-4B next-token/word distribution

Источники:

- `research/qwen_next_token_word_distribution_ru.ipynb`
- `research/qwen_next_token_word_distribution_report.md`

Конфигурация прогона:

Параметр	Значение
Модель	Qwen/Qwen3-4B-Base
Dataset	ag_news , split test
Количество примеров	32
Prefix words	3
Batch size	2
Device	CPU
Параметров модели	4,022.5M

Ключевые метрики:

Метрика	Значение
Средняя entropy по отдельным prompt	5.1206
Entropy <code>mean(softmax(logits))</code>	7.2851
Entropy <code>softmax(mean(logits))</code>	6.6238
Jensen-Shannon divergence между агрегациями	0.166515
Top-20 overlap	11/20
Масса BoW word approximation	0.6437

Главный вывод: для оценки среднего поведения модели по корпусу корректнее усреднять уже нормированные вероятности:

```
mean(softmax(logits))
```

а не применять softmax к средним logits:

```
softmax(mean(logits))
```

В текущем эксперименте `softmax(mean(logits))` сделал распределение более острым и сместил top-token интерпретацию.


Тор-10 токенов по корректной агрегации:

Rank	Token	Mean prob
1	' a'	0.0267247
2	'<space>'	0.0259820
3	' to'	0.0234306
4	':'	0.0208896
5	' on'	0.0201004
6	' the'	0.0190602
7	' and'	0.0190483
8	' in'	0.0185953
9	''s"	0.0177981
10	' optimization'	0.0148783


Тор-10 приближенных следующих слов:

Rank	Word	Approx prob
1	a	0.0282516
2	on	0.0262634
3	to	0.0245393
4	the	0.0208050
5	in	0.0204358
6	and	0.0192319
7	optimization	0.0150310
8	of	0.0148890
9	is	0.0147133
10	down	0.0101265


Графики эксперимента:




Token distribution comparison



Cumulative top-k mass



Entropy by AG News label



Approximate next-word distribution

Ограничение: word-level распределение здесь является BoW-аппроксимацией по top word-start токенам. Это полезно для интерпретации, но не равно полной Pimentel & Meister маргинализации по всем субсловным путям.

MECW и контекстное окно

Источники:

- [research/Исследование контекстного окна LLM.pdf](#)
- [research/llm_context_window_mecw_ru.ipynb](#)

- `research/llm_context_window_results_ru.md`
- `research/hypothesis.md`

Что реализовано

Notebook превращает теоретический отчет по context window/MECW в исполняемый прототип:

1. Pimentel & Meister word probability correction. 2. Sampler-free confidence metrics. 3. Dynamic MECW detection. 4. N-gram perplexity elbow method. 5. SATLUTION/Kairos L2 state management через `research/hypothesis.md`.

Фактический прогон русского notebook

По `research/llm_context_window_results_ru.md`:

Параметр	Значение
Выполнено code cells	10
Ошибок выполнения	0
Сохраненных PNG-графиков в outputs	5
Время выполнения	примерно 260 секунд
Device	CPU
Изолированная среда	<code>research/.venv_nb_exec</code>
Модель demo	<code>gpt2</code>

Pimentel & Meister correction

Метрика	Значение
Наивная subword probability	<code>9.768e-04</code>
Исправленная word-level probability	<code>9.496e-04</code>
Correction factor	<code>0.972</code>
BoW-токенов найдено	33,139

Интерпретация: в демо-примере коррекция уменьшила вероятность примерно на 2.8%. Это подтверждает практическую проблему: token-level вероятность нельзя без проверки считать word-level вероятностью.

Sampler-free confidence metrics

Метрика	Значение
<code>ci_width_proxy</code>	0.5006
Средняя entropy	4.6111
Средний <code>top1_margin</code>	0.1463
Средний <code>hidden_iqr</code>	0.5419
Средняя trajectory energy	50.9133

Интерпретация: confidence оценивалась без stochastic sampler, через logits и hidden states. Это важно, потому что sampler вносит случайность и мешает понять, где неопределенность модели, а где эффект случайного выбора предыдущих токенов.

MECW detection

B notebook report:

Метрика	Значение
breached	True
breach_index	72 tokens
max_variance	3.594e-03
epsilon	1.000e-10

B [research/hypothesis.md](#) L2 buffer дополнительно содержит MECW flush entries c:

Метрика	Значение
event	MECW_BREACH_CONTEXT_FLUSH
breached	true
breach_index	96
window_step	24
token_count before flush	337
max_variance	0.0056388184780660384

Разница между breach index 72 и 96 связана с разными demo runs/flush entries. Обе записи являются локальными фактическими outputs, но порог `epsilon=1e-10` был намеренно чувствительным, чтобы показать механизм flush.

N-gram demo и n sweep

N-gram demo:

Метрика	Значение
Unique n-grams	43
Perplexity values	[7339.72, 7326.40, 3038.45, 1803.94, 1803.94]
Elbow point	около 8 chunks


Sweep по `n=1..10`:

n	Unique	Elbow chunks	Elbow PPL	Post-elbow instability	Score
1	44	8	278700.45	0.0305	0.769
2	44	6	23676.69	0.0362	0.538
3	43	8	3723.19	0.0000	0.141
4	42	6	1109.62	0.0000	0.012
5	41	6	991.83	0.0000	0.000

n	Unique	Elbow chunks	Elbow PPL	Post-elbow instability	Score
6	40	6	1153.15	0.0000	0.016
7	39	6	3423.27	0.0000	0.132
8	38	4	3563.60	0.0000	0.136
9	37	4	3912.90	0.0000	0.146
10	36	4	7624.24	0.0000	0.217

В демо-прогоне лучший размер n-граммы: **n=5** . Это не универсальная константа, а результат конкретного маленького демо-корпуса.


Графики MECW notebook:




MECW graph 1




MECW graph 2



MECW graph 3



MECW graph 4



MECW graph 5

Large-corpus n-gram sweep

Источники:

- [research/large_corpus_ngram_perplexity_entropy_report.md](#)
- [research/large_corpus_ngram_perplexity_entropy_ru.ipynb](#)
- [research/large_ngram_sweep_metrics.png](#)
- [research/.gitignore](#)

Эти файлы есть в рабочем дереве, но внесены в `research/.gitignore`. Значит, это важный локальный результат, но не tracked artifact истории репозитория.

Конфигурация

Параметр	Значение
Dataset	HuggingFaceFW/fineweb-edu
Config	sample-10BT
Split	train
Documents	1,627
Bytes streamed	8,001,974
Model	Qwen/Qwen2.5-0.5B
Device	CPU
N values	[1, 2, 3, 5, 10, 25, 50, 100, 250, 500, 1000]
Target stream bytes	8,000,000
Max model blocks per n	8
Model block tokens	256


Итоговая таблица

n	Unique	Sampled	CE	PPL	N-gram H bits	Model H bits	Score	Valid
1	14,331	50,000	7.7895	2415.18	12.390	12.130	0.810	True
2	46,900	50,000	8.2807	3947.08	15.445	12.133	0.757	True
3	49,774	50,000	7.5525	1905.53	15.600	2.437	0.416	True
5	49,959	50,000	7.6331	2065.51	15.608	10.568	0.599	True
10	49,986	50,000	6.8708	963.76	15.609	10.070	0.448	True
25	49,996	50,000	6.3325	562.56	15.609	9.829	0.344	True
50	49,999	50,000	5.8588	350.29	15.610	8.928	0.238	True
100	49,999	50,000	5.5802	265.12	15.610	4.401	0.093	True
250	50,000	50,000	5.2932	198.98	15.610	6.464	0.083	True
500	50,000	50,000	5.4248	226.97	15.610	7.331	0.125	True
1000	50,000	50,000	5.4794	239.71	15.610	6.700	0.122	True

Лучший score в этом run: n=250 .

Фактические значения для n=250 :

- CE: **5.2932**;
- PPL: **198.98**;
- model next-token entropy: **6.464 bits**;
- empirical n-gram entropy: **15.610 bits**;
- unique n-grams: **50,000**.



Large n-gram sweep

Ограничение: 8 MB stream не доказывает универсальность n=250 . Это результат конкретной связки corpus/model/run: fineweb-edu sample-10BT + Qwen2.5-0.5B + CPU inference + выбранный score. При увеличении TARGET_STREAM_BYTES до 1GB итог может сдвинуться, но сама методика сравнения останется применимой.

Метрики оценки pretrain

Источник: [metrics.md](#)

Для оценки pretrain/continued-pretrain качества в репозитории выделены:

Метрика	Что измеряет	Практическое применение
Log-Likelihood	Суммарную уверенность модели в реальных токенах	Базовая оценка вероятности текста
Cross-Entropy Loss	Среднюю отрицательную log-probability	Основная training/validation loss
Perplexity	Экспоненту от CE	Интерпретируемая мера "удивления" модели
Few-Shot Accuracy	Выбор правильного ответа по conditional likelihood	MMLU/GSM8K и похожие задачи
Pass@k	Вероятность получить корректное решение среди k генераций	Код/генерация
KL-Divergence	Расхождение выходных распределений	Близость поведения к reference модели

Важный методологический вывод: напрямую сравнивать вектора весов через L2/cosine **бессмысленно** как критерий похожести моделей. Причины: симметрии архитектуры, стохастичность оптимизации, permutation-like эффекты и то, что одинаковое поведение может соответствовать разным координатным представлениям весов.

Практический baseline:

- запускать одинаковые версии бенчмарков через `lm-evaluation-harness` ;
- сравнивать с Qwen-family baseline, в заметках указан `Qwen3.5-0.8B-Base` ;
- считать PPL на независимом validation split;
- для близости поведения использовать KL-div по фиксированному набору prompts;
- держать одинаковые few-shot примеры, prompt templates, batch/eval config.

Что пока не сделано

На текущем срезе в репозитории не зафиксированы:

- полный pretrain или continued-pretrain запуск собственной модели;
- финальная спецификация data mix на 50-70B токенов;
- production-grade filtering pipeline с воспроизводимым seed selection, negatives, classifier training, validation и final filtering;
- воспроизводимая training-инфраструктура, включая ZeRO configs;
- training logs, checkpoints и финальные eval tables собственной модели;
- стабильный artifact registry: часть outputs находится в notebook cells, Colab paths, локальных ignored cache/artifact файлах;
- строгая word-level probability marginalization для большого корпуса: текущий Qwen3-4B word-level слой является приближением.

Практический статус проекта

Проект находится на стадии исследовательского прототипирования перед полноценной training-инфраструктурой.

Что уже есть:

- понятная постановка через встречи и гипотезы;
- список датасетов и рабочая смесь;
- первый corpus sample и tokenizer/bin path;
- диагностические эксперименты с распределениями Qwen;
- работающий MECW/context-window prototype;
- фактический large-corpus n-gram sweep на Qwen2.5-0.5B;
- метрики для будущей оценки pretrain.

Что является ближайшим инженерным переходом:

- превратить notebooks в воспроизводимые scripts/pipeline;
- закрепить data mix и фильтрационные критерии;
- сохранить все generated artifacts в предсказуемой структуре;
- подготовить минимальный continued-pretrain run с логам, validation PPL и baseline comparison;
- отделить demo thresholds от production thresholds.

Итоговая оценка: репозиторий уже содержит содержательные фактические исследования и прогоны кода, особенно по распределениям, MECW и n-граммам. Но он пока не доказывает, что собственная модель обучена; он доказывает, что подготовлена и частично проверена исследовательская база для перехода к воспроизводимому pretrain/continued-pretrain pipeline.